

## Teile und (Be-) Herrsche

Einführung in Bayessche Hierarchische Modelle

IFM Workshop, 28.01.2021

Dr. Sven Thies



#### AGENDA

#### 1. Theorie

- i. Machine Learning vs. Statistische Modellierung
- ii. Grundlagen der Bayesschen Modellierung
- iii. Pymc3 Ein probabilistisches Programmierframework

#### 2. Praxis

- i. Unsicherheit beherrschen: Bayessche Lineare Modelle
- ii. Informationen teilen: Bayessche Hierarchische Modelle

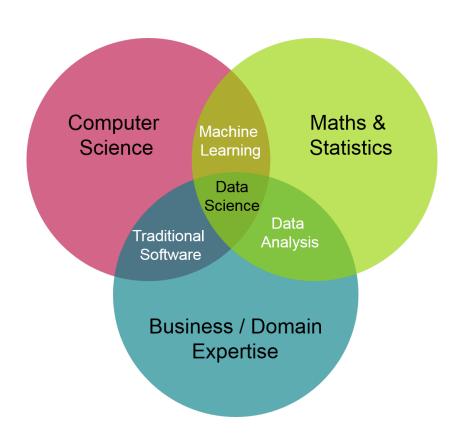




#### Unterschiedliche Hintergründe bestimmen Weltbild und Herangehensweise

#### **Der Informatiker**





#### Der Statistiker



© INFOMOTION GmbH 27, Januar 2021 4



# Machine Learning vs. Statistische Modellierung Data Science Stereotypen

#### ... als Data Scientist

#### **Der Informatiker**



Verwendet Python (TF, sklearn)

Große Datensätze sind notwendig

Sorgt sich um Overfitting

Prüft die Vorhersagekraft

Verwendet nichtlineare Modelle

Modelle sind oft Black-Box

Strebt nach Automatisierung

#### Der Statistiker



Quelle: In Anlehnung an "Machine Learning and Statistics: Don't Mind the Gap", Thomas Wiecki, ODSC Europe, 2018

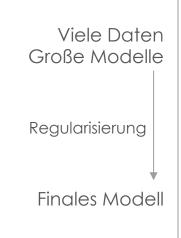


#### Data Science Prozess der Prädiktiven Modellierung

#### ... als Data Scientist

#### **Der Informatiker**







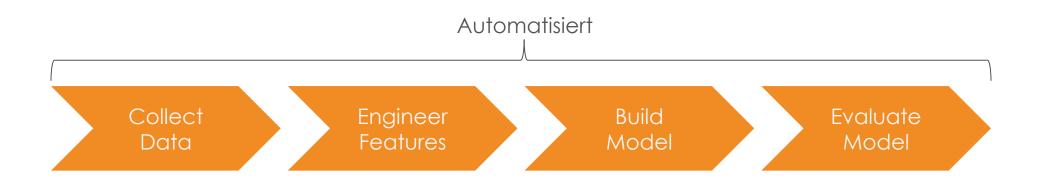
Machine Learning-Ansatz

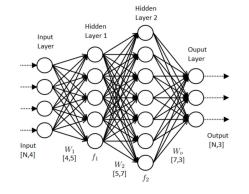
#### **Der Statistiker**

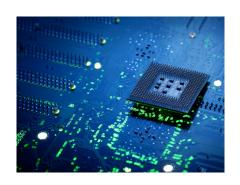




#### Prozess der Prädiktiven Modellierung nach Informatikern









# Machine Learning vs. Statistische Modellierung Data Science Stereotypen

#### ... als Data Scientist

#### **Der Informatiker**



Verwendet Python (TF, sklearn)

Große Datensätze sind notwendig

Sorgt sich um Overfitting

Prüft die Vorhersagekraft

Verwendet nichtlineare Modelle

Modelle sind off Black-Box

Strebt nach Automatisierung

Verwendet R

Große Datensätze sind Problem

Sorgt sich um Annahmen

Prüft asymptotisches Verhalten

Verwendet lineare Modelle

Modelle sind verständlich

Strebt nach Erkenntnis

#### Der Statistiker



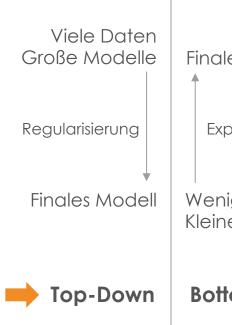
Quelle: In Anlehnung an "Machine Learning and Statistics: Don't Mind the Gap", Thomas Wiecki, ODSC Europe, 2018

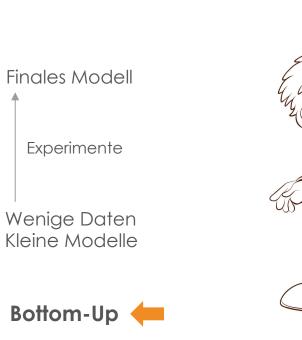


#### Data Science Prozess der Prädiktiven Modellierung

#### ... als Data Scientist

**Der Informatiker** 







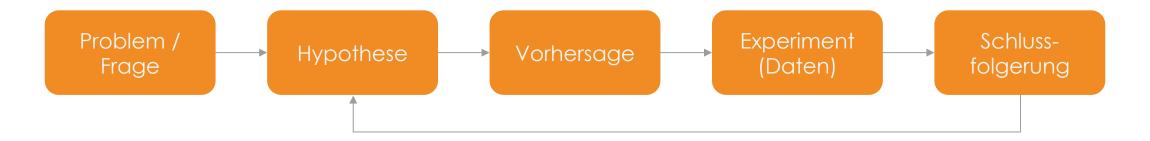
Der Statistiker

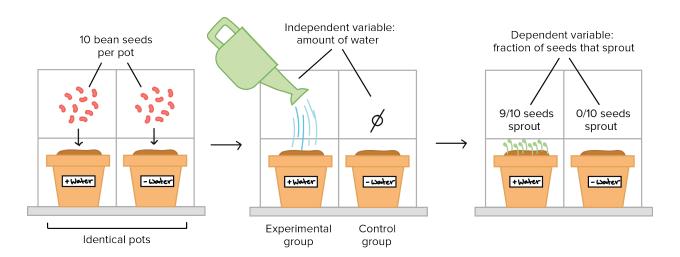
Machine Learning-Ansatz

Inferenz-basierter Ansatz



#### Prozess der Prädiktiven Modellierung nach Statistikern

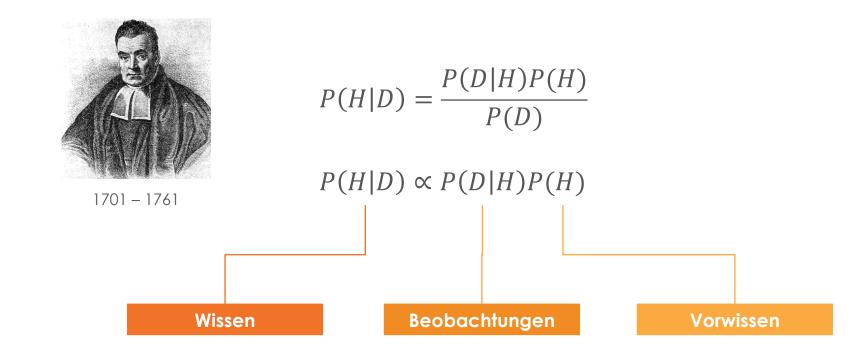








#### Mathematische Formulierung des wissenschaftlichen Prozesses: Der Satz von Bayes





#### Das Posteriori Wissen ist eine Kombination von A-Priori Wissen und Beobachtungen

#### **Posterior Probability**

Die Wahrscheinlichkeit, dass die Hypothese wahr ist, nachdem wir die Daten gesehen haben.

#### Likelihood

Die Wahrscheinlichkeit der beobachteten Daten, angenommen, die Hypothese sei wahr.

#### **Prior Probability**

Die Wahrscheinlichkeit, dass die Hypothese Wahr ist (bevor wir die Daten gesehen haben).

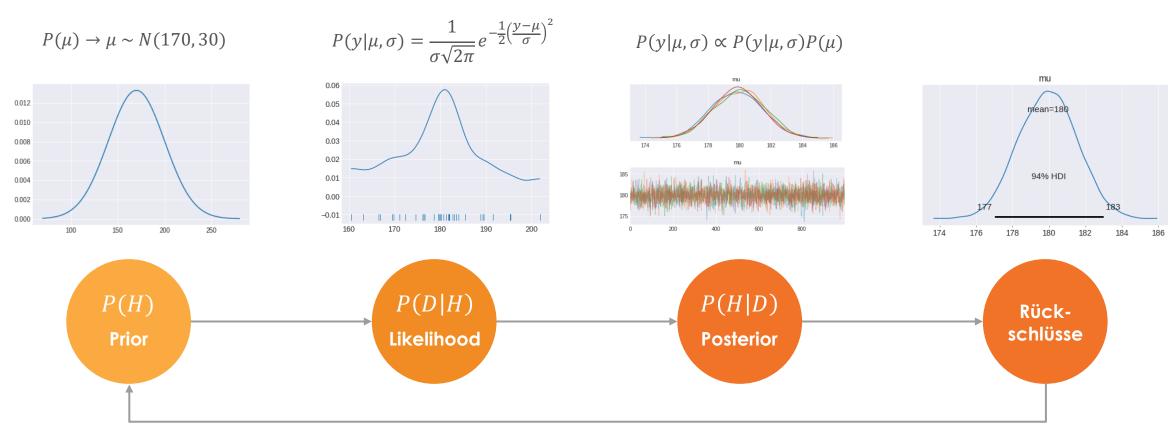
 $P(H|D) \propto P(D|H)P(H)$ 

Alles wird als Verteilung dargestellt

Vorwissen wird genutzt



#### Prozess der Bayesschen Modellierung



Bayesian Updating (of believes)



## Pymc3 – Ein probabilistisches Programmierframework



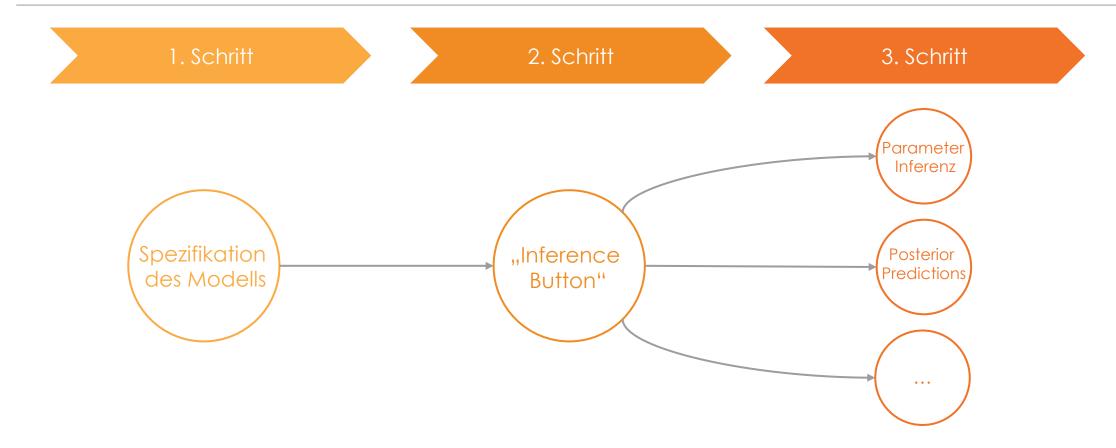
## Pymc3 – Ein probabilistisches Programmierframework

### Vereinfachte Bayessche Modellierung mit Pymc3



- Leicht zu bedienende API
- Starkes Backend f

  ür Sampling





## Praxis